

乐天知性·安心答

AI + 性健康与亲密关系·社会学升维陪伴 + 适龄双版本 | GOAI 世界人工智能开源大赛·赛道二 无界应用
| MIT 开源

我们解决什么

- 性教育长期「学校不敢讲、家庭不会讲、网络乱讲」；市面只有教科书式(枯燥)或猎奇擦边(无护栏、夹带PUA)两类极端。
- 视角空白：内容只在「知识」层打转，缺把个体困惑与原生家庭/阶层/身份挂钩的「升维」解释——年轻人最想被理解的维度。
- 适龄段空白：现有性健康 bot 几乎全 18+ 成人向，未成年版(12-18)在公开样本中极少占；青少年早熟≠懂，处于高风险区。

差异化定位 (核心评分点)

- 做「第四类」：知识 + 结构视角 + 适龄分级 + 安全 + 社区；不做教科书/猎奇/PUA 物化。
- 五层架构：知识 → 升维 → 多元(去污名,consent前置) → 社群(18+论坛+展讯,规划) → 适龄(未成年版动漫/游戏化,独立应用不挂成人库)。
- 双版本壁垒：身份/年龄认证分流，后端两个独立应用、未成年版不挂成人知识库；绝不性化未成年人，未成年版零色情/零性暗示/零SM。

系统架构 & 已跑通

- 成年版 Chatflow 5 节点链路已在 Dify 实跑：用户输入 → kb_adult 检索(TopK=3) → 条件分支 → 阶跃 Step 3.7 Flash + 7条规则 → 回复(含来源)。
- 技术栈：阶跃 StepFun + Dify Chatflow(主力,可私有化) + FastGPT(对照) + 规划中的 ShieldLM-6B/LlamaGuard S1-S13/DFA(四层审核) + 单文件 index.html + Cloudflare Pages。

安全合规 (核心评分点)

- 18+ 硬门槛(第一道墙) + 七条强制安全规则(AGE_GATE/NO_PORN/CONSENT_FIRST/SELF_HARM/VIOLENCE/MEDICAL/SOURCE_TAG)。
- 规划中的四层审核 + Llama Guard S4(规划采用,儿童性剥削)零容忍硬拦；危机转介用已核实热线白名单(12356/12338/12355/110/120)，设过期复核。

评测方案 (核心评分点)

- 三组对照：A 裸模型 / B Dify版(主方案) / C FastGPT版；测试集 152 条(知识31/升维38/安全37/拒答转介46)；红队 47 条。
 - 五维评分 Rubric(0-2)：知识形式合规/升维质量/安全合规/拒答恰当/引用规范；红队以拦截率为核心指标。
- 评测/红队真题图因 kb_adult 检索空(A5)未闭环，仍为「模拟占位」，待 A5 闭环按 REPORT_DATA_SLOTS.md 一键替换为实测 v1；评分器为正则启发式自动初筛分，非人工评分。

开源贡献 & 落地

- MIT 开源：index.html 原型 / SYSTEM_PROMPT(+MINOR) / 知识库索引 / 评测红队套件 / 双版本与品牌设计文档；公开升维框架+规划中的四层审核+适龄分级范式。
- 比赛：goaih2.com 报名 → 初赛(8/16截止) → 复赛(8/25-9/3) → 决赛(9/22-23 杭州)。真实上线需 ICP+网文证+内容审查，Key 经密钥管理注入不落库。

边界声明：本项目是教育辅助工具，非医疗/心理咨询替代品。关键节点 □ 8/15 MVP 冻结 | □ 8/16 初赛提交。